TÌM KIẾM ẢNH VĂN HÓA VIỆT NAM

Tìm ảnh theo nhu cầu, không chỉ theo tên.

Tên / Mô tả tự nhiên / Ảnh tham chiếu

“Nghệ nhân hướng dẫn trẻ làm gốm”

Đúng chủ đề → Đúng thuộc tính → Đúng quan hệ

Đã có pipeline • Cần benchmark • Xin góp ý hướng phát triển







Ảnh từ corpus hiện tại

01 / HIỆN TRẠNG

Pipeline đã chạy trên toàn bộ corpus

15.423
asset sau khử trùng lặp

15.411
asset được tìm kiếm

768
chiều / vector SigLIP2

Dữ liệu & embedding

6 nhóm văn hóa • hash khử trùng lặp
Vector ảnh + metadata • Kaggle → HF

Ứng dụng & retrieval

Web + API • keyword / semantic / hybrid
Router, cache, planner / rerank tùy chọn

12 asset cách ly. Pipeline hoạt động; chất lượng tổng thể cần benchmark có nhãn.

02 / KIẾN TRÚC

Chọn luồng xử lý theo truy vấn



*Chỉ nhánh LLM khi được bật; có thể hỏi rõ trước retrieval.

NumPy exact local • HF lưu artifact • Qdrant chưa phục vụ search

03 / MINH HỌA HIỆN TẠI

Kết quả quan sát ≠ benchmark chất lượng

TÊN RÕ RÀNG

bánh chưng



lexical · 0 lần gọi LLM

MÔ TẢ TRỰC TIẾP

ruộng bậc thang xanh ở vùng núi



hybrid · 0 lần gọi LLM

NHIỀU ĐIỀU KIỆN

áo dài đỏ, không đội nón



hybrid · 0 lần gọi LLM
Local dự phòng — xem evidence

200 query đã tạo • Chưa chấm nhãn • Chưa công bố recall

04 / ĐÁNH GIÁ

Đo đúng chỉ số, ở đúng tầng

CHỈ SỐ	CÂU HỎI CẦN TRẢ LỜI	DÙNG KHI NÀO?
Latency p50 / p95	Request thường / chậm mất bao lâu?	Benchmark & vận hành
Recall@K	Thu hồi bao nhiêu trong tất cả ảnh đúng?	Chọn tập ứng viên
Precision@K	Bao nhiêu ảnh trả về đáp ứng yêu cầu?	Danh sách cuối
nDCG@K	Ảnh phù hợp hơn có đứng cao hơn?	Fusion & rerank
ANN Recall@K	Giữ bao nhiêu top-K của exact search?	Thử ANN / nén vector

Ví dụ minh họa: 20 ảnh đúng, top 10 có 6 ảnh đúng

Recall@10 = 6/20 = 30% | Precision@10 = 6/10 = 60%

HitRate ≠ Recall. ANN recall ≠ relevance. Pool chưa đầy đủ ≠ corpus ground truth.

05 / TỐI ƯU HỆ THỐNG

Tối ưu từ phần đang tốn tài nguyên

6,51
GiB ảnh gốc
15.719 file

90,4 MiB
hai ma trận vector float32

Storage

Ảnh theo hash + thumbnail → object storage / CDN
Metadata, vector và phiên bản liên kết bằng asset ID

Latency

Đo routing → encode → retrieval → LLM / rerank
Warmup & cache đã có nền tảng; ANN khi có nút thắt

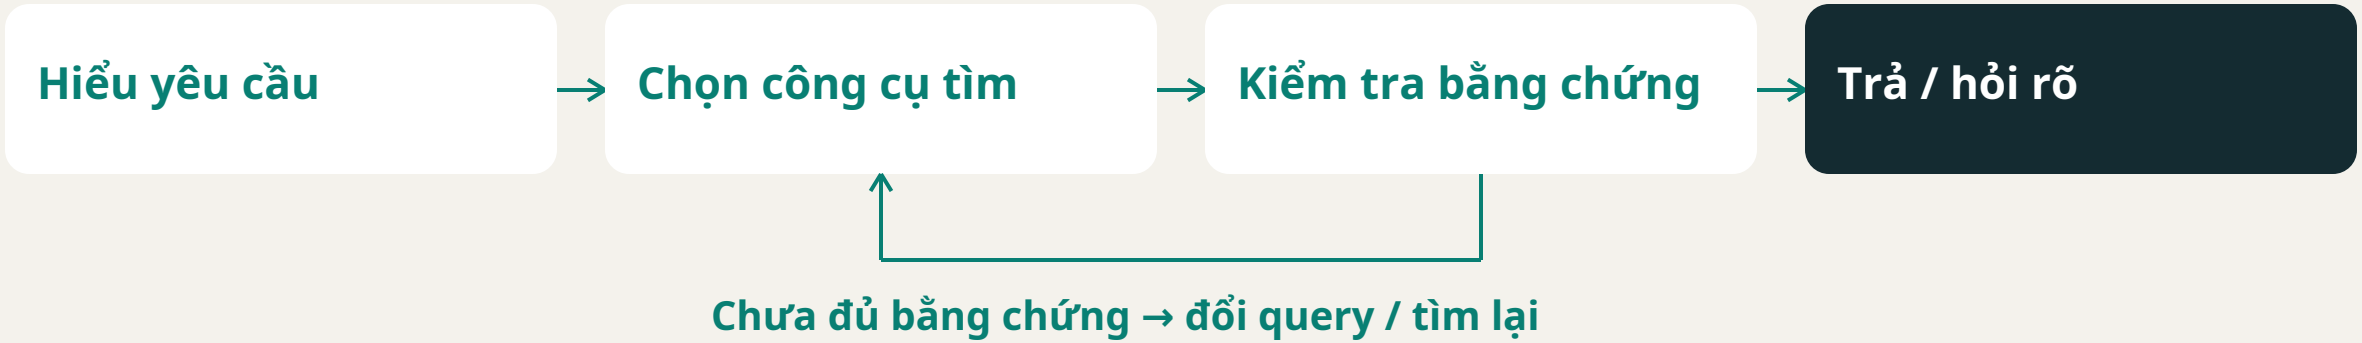
Đo cold / warm • cache hit / miss • concurrency • API và hiển thị ảnh

Thử ANN / quantization: so tốc độ, RAM/disk và chất lượng với exact baseline.

06 / HƯỚNG MỞ RỘNG

Agent search: tìm, kiểm tra, rồi quyết định

HIỆN CÓ: router + planner + retrieval + rerank theo luồng định sẵn



Thử nghiệm nhỏ

Query khó • Trong corpus • Tối đa 2 vòng retrieval

Giữ nếu có giá trị

Đáp ứng điều kiện ↑ / latency & chi phí chấp nhận được

Hai nhóm độc lập ≠ một cảnh nhiều điều kiện. Agent vẫn dùng retriever và dữ liệu hiện có.

07 / THẢO LUẬN

Xin góp ý để chọn bước tiếp theo

01 Bộ query và cách chấm relevance đã đúng bài toán?

02 Ưu tiên metadata, retrieval hay kiểm chứng bằng ảnh?

03 Trường hợp nào cần agent search để tạo giá trị rõ?

Benchmark có nhãn → Sửa lỗi chất lượng → Tối ưu hệ thống → Thử agent

Chốt ngưỡng chất lượng và latency dựa trên baseline + nhu cầu sử dụng.